Rapport général — Atelier Pratique : Détection d'anomalies

Master 2 Data Science — Université Claude Bernard Lyon 1

1. Protocole

- **Jeux de données :** Credit Card (283 726 transactions uniques après suppression de 1 081 doublons, 473 fraudes), AI4I 2020 (Partie 4, données synthétiques), Mouse (Parties 1 et 5.1, données 2D pédagogiques, 500 points dont 10 anomalies).
- **Découpage Credit Card / AI4I :** stratifié 60 % Train / 20 % Validation / 20 % Test, `random_state=42`. Sur Credit Card, la variable `Time` est écartée des prédicteurs ; le risque de fuite temporelle d'un découpage aléatoire est discuté. Sur Mouse, ce découpage 60/20/20 n'est **pas** appliqué (protocole spécifique outliers / nouveautés du sujet).
- **Prétraitements ajustés sur le Train uniquement :** `RobustScaler` sur `Amount` (Credit Card) ; `OneHotEncoder` sur `Type` et `StandardScaler` sur les numériques (AI4I).
- **Règle de décision (Credit / AI4I) :** sur la Validation, seuil maximisant le rappel sous contrainte de précision (Credit : ≥ 80 % ; AI4I : ≥ 90 %) et au moins une alerte. Si la contrainte n'est pas atteinte, seuil à F1 maximal, avec le statut « non atteint ». Le seuil est ensuite figé et appliqué au Test sans modification.
- **Garde-fous contre la fuite de données :** suppression des doublons avant partition, scalers ajustés sur le Train, SMOTE appliqué au Train seul, colonnes de types de panne retirées sur AI4I, fond SHAP tiré du Train.

2. Partie 1 — Mouse (outliers, seuils, nouveautés)

- **Protocole :** labels construits avant mélange (10 derniers points = anomalies) pour l'évaluation seulement. IF (`contamination=0.02`) et LOF en outliers ; scores ↑ = plus suspect. Trois règles de seuil **sans tuner avec y** : défaut, IQR (Q3 + 1.5 × IQR), clustering KMeans (k = 2) sur les scores. Classement via AP / AUC-ROC. Nouveautés : train 100 % normal, LOF `novelty=True`, évaluation sur test réservé.

Méthode	Règle de seuil	Nb alertes	F1 anomalie
Isolation Forest	Défaut (`contamination=0.02`)	10	**0.90**
Isolation Forest	IQR	21	0.65
Isolation Forest	Clustering (KMeans k = 2)	115	0.16
LOF	Défaut	10	**1.00**

Méthode	Règle de seuil	Nb alertes	F1 anomalie
LOF	IQR	37	0.43
LOF	Clustering (KMeans k = 2)	8	0.89

- **Lecture :** avec `contamination=0.02`, le défaut IF est déjà très bon (9 TP, 1 FP, 1 FN). IQR/clustering ne remplacent pas ce réglage : clustering trop sensible pour IF ; IQR trop large pour LOF. Meilleur F1 outliers : **LOF + défaut**.
- **Classement :** IF AP ≈ 0.96, AUC ≈ 0.999 ; LOF AP = 1, AUC = 1. Modifier seulement le seuil change F1 / confusion, **pas** AP/AUC.
- **Nouveautés (LOF) :** train 343 normaux ; test 157 dont 10 anomalies ; F1 ≈ 0.86, AP ≈ 0.98 (9 TP, 2 FP, 1 FN).
- **Limite Mouse :** 10 anomalies seulement → conclusions fragiles à 1–2 erreurs ; résultats descriptifs de l'échantillon, pas une estimation future.

Interprétation des résultats (Mouse)

La supériorité de l'algorithme LOF (Local Outlier Factor) sur ce jeu de données en deux dimensions s'explique par sa nature fondée sur la densité locale. Contrairement à l'Isolation Forest qui isole les points par des coupes aléatoires (plus adaptées à la recherche d'anomalies globales), LOF détecte les variations de densité par rapport aux voisins immédiats. Dans le jeu de données Mouse, les anomalies (telles que les points formant le nez ou les oreilles de la souris) constituent de petits groupes ou s'éloignent localement de structures très denses. Le paramétrage par défaut de LOF s'avère parfaitement calibré pour cette topologie, identifiant les anomalies sans générer de faux positifs. L'échec des méthodes de seuillage par clustering (KMeans) sur les scores d'anomalie montre que la distribution de ces scores n'est pas bimodalement nette : forcer une séparation par K-Means entraîne soit une sous-détection, soit une sur-détection massive.

3. Résultats principaux (Credit Card, Test : 56 746 transactions, 95 fraudes)

Modèle	Seuil (Val)	Précision	Rappel	AP	TP	FP	FN	Contrainte ≥ 80 %
Régression logistique (C = 0.01, SMOTE sur Train) — retenue	**0.999996**	**87.95 %**	**76.84 %**	0.7098	73	10	22	**Respectée**
Arbre de décision (`max_depth=5`, sans correction)	0.0500	85.23 %	78.95 %	0.7403	75	13	20	Respectée

Modèle	Seuil (Val)	Précision	Rappel	AP	TP	FP	FN	Contrainte ≥ 80 %
EasyEnsemble (5 sous-ensembles)	0.6640	79.31 %	72.63 %	0.7288	69	18	26	Non respectée
Isolation Forest (non supervisé)	0.6337	23.23 %	37.89 %	0.2668	36	119	59	Non respectée
LOF (non supervisé)	2.6744	54.70 %	67.37 %	0.5031	64	53	31	Non respectée

- **Modèle retenu :** la régression logistique avec SMOTE (C = 0.01). Sur la Validation, elle atteint la contrainte de précision (0.8276) avec le meilleur rappel (0.766). Le modèle et son seuil sont fixés sur la Validation, puis appliqués au Test.
- **Détecteur non supervisé :** les hyperparamètres de chaque détecteur sont choisis par AP sur la validation (LOF `n_neighbors=100` : 0.4060 ; Isolation Forest `n_estimators=100`, `max_samples=1024` : 0.1516). Aucun des deux n'atteint la contrainte de précision ≥ 80 % ; en validation, LOF a le rappel le plus élevé (0.6064 contre 0.3617) et le F1 le plus élevé (0.5644 contre 0.2833), il est donc retenu comme meilleur compromis. Isolation Forest reste utilisé pour l'explication SHAP (Partie 5.2), comme comparateur (Parties 2 et 3) et comme modèle repris en Partie 4 (AI4I).
- **Seuil :** $\tau = 0.999996$. Ce seuil très proche de 1 s'explique par SMOTE, qui modifie les probabilités prédites. Sur la Validation, au seuil par défaut 0.5, la précision tombe à 5.69 % (rappel 85.11 %) : le seuil par défaut n'est pas utilisable après SMOTE.
- **Lecture sur le Test :** 83 alertes, dont 73 fraudes (précision 87.95 %) et 10 fausses alertes ; 22 fraudes échappent à la détection. La contrainte est respectée sans modification du seuil.
- **Arbre de décision :** sur le Test, il fait un rappel légèrement supérieur (78.95 % contre 76.84 %, soit 75 fraudes contre 73) pour 13 fausses alertes au lieu de 10. L'écart est de deux fraudes sur 95 : il ne remet pas en cause le choix, fait sur la Validation.
- **Partie 2 (variantes) :** SMOTE et la pondération n'améliorent pas l'arbre, dont la précision chute sous 56 % avec ces deux variantes.
- **Non supervisés :** Isolation Forest et LOF ont une AUC-ROC correcte mais une précision insuffisante ; ils ne peuvent pas servir de décision binaire directe.

Interprétation des modèles et du seuil (Credit Card)

Le comportement de la **régression logistique avec SMOTE** illustre parfaitement l'impact des techniques de suréchantillonnage sur la calibration des probabilités. En rééquilibrant artificiellement les classes lors de l'entraînement, SMOTE décale drastiquement la distribution des probabilités prédites vers le haut pour la classe minoritaire (fraude). Par conséquent, le seuil par défaut de 0.5 devient obsolète, générant une quantité inacceptable de faux positifs (la précision chute à ~5.7 %). Pour respecter la contrainte stricte de 80 % de précision, le seuil doit être repoussé à une valeur extrême (0.999996). Cette valeur ne traduit pas une certitude mathématique absolue du modèle, mais représente un recalibrage empirique indispensable pour filtrer le bruit induit par la génération synthétique de SMOTE.

Concernant les **modèles non supervisés** (Isolation Forest et LOF), leur incapacité à atteindre la contrainte de précision (plafonnant respectivement à 23 % et 54 %) souligne la différence fondamentale entre une "anomalie statistique" et une "fraude avérée". Ces algorithmes détectent des transactions géométriquement rares dans l'espace des variables. Or, une transaction peut être atypique dans son comportement (par exemple, un achat d'un montant exceptionnel à une heure inhabituelle par un client régulier) sans pour autant être frauduleuse. Sans la cible supervisée pour corriger et guider la frontière de décision, ces détecteurs génèrent un volume de fausses alertes trop important pour déclencher un blocage automatique de carte bancaire.

4. Méthode recherchée et sources

- **Méthode testée en Partie 3 :** EasyEnsemble (Liu, Wu & Zhou, 2009), proposée sur les conseils de l'enseignant. Elle entraîne plusieurs AdaBoost, chacun sur un sous-ensemble équilibré formé de toutes les fraudes et d'un échantillon de transactions normales, puis moyenne leurs scores. Elle exploite ainsi la classe majoritaire sans que le déséquilibre domine l'apprentissage.
- **Résultat :** AP de 0.7288 sur le Test, proche de la régression logistique (0.7098), mais précision de 79.31 %, sous la contrainte. Le seuil gelé est rapporté tel quel.
- **Autres références :** Isolation Forest (Liu, Ting & Zhou, 2008), LOF (Breunig et al., 2000), SMOTE (Chawla et al., 2002), SHAP (Lundberg & Lee, 2017).

5. Partie 4 — Transfert à la maintenance prédictive (AI4I 2020)

- **Protocole de transfert :** reprendre les modèles retenus sur Credit Card (**hyperparams figés**), les **réajuster** sur AI4I, et **recalibrer** le seuil (précision ≥ 90 %) sans réutiliser la valeur numérique du seuil fraudes.

- IF : `n_estimators=100`, `max_samples=1024`, `contamination="auto"` ;
  - LR : `C=0.01` + SMOTE sur le Train ;
  - cible `Machine failure` ; colonnes d'identifiants et de types de panne retirées (fuite) ;
  - évaluation via les fonctions Credit (`trouver_meilleur_seuil`, `evaluer_seuil`) sans les modifier.

Validation (choix du seuil) :

Méthode	Seuil	Précision	Rappel	TP	FP	FN	AP	AUC
Isolation Forest	≈ 0.68	1.00	0.029	2	0	66	0.14	0.77
Régression logistique (C = 0.01, SMOTE)	≈ 0.96	0.90	0.132	9	1	59	0.39	0.88

Test (seuils figés) :

Méthode	Précision	Rappel	TP	FP	FN
Isolation Forest	1.00	0.015	1	0	67
Régression logistique	1.00	0.029	2	0	66

- **Lecture :** LR > IF en ranking (AP/AUC). Sous précision ≥ 90 %, les seuils deviennent très exigeants → peu d'alertes, rappel très bas, beaucoup de FN (pannes manquées). Sur le Test, la précision reste haute mais le système détecte presque aucune panne. FP = interventions inutiles ; FN = pannes manquées.
- **Conclusion 4.e :** le succès Credit Card ne se transfère pas automatiquement (autre cible, autres variables, ≈ 3.4 % de pannes contre ≈ 0.17 % de fraudes, contrainte plus dure). On ne compare pas directement les AP des deux jeux.

Interprétation de l'échec du transfert

L'effondrement du rappel (passant de ~77 % sur Credit Card à moins de 3 % sur AI4I) lors du transfert des pipelines démontre les limites de la généralisation d'un modèle d'un domaine à un autre. La contrainte métier imposée (précision ≥ 90 %) est extrêmement punitive sur le jeu AI4I car les distributions des observations "normales" et des "pannes" (Machine failure) se chevauchent fortement dans l'espace des descripteurs physiques (température, vitesse de rotation, couple, usure de l'outil). Pour garantir qu'au moins 9 alertes sur 10 soient de véritables pannes, le seuil de décision doit être fixé de manière si restrictive que le modèle ne déclenche une alerte que sur les cas d'une évidence caricaturale. Opérationnellement, un tel système est inutile : il manque 97 % des pannes réelles (Faux Négatifs), ce qui, dans un contexte de maintenance industrielle, se traduirait par des casses machines non anticipées et des arrêts de production très coûteux.

6. Partie 5 — Robustesse et explicabilité

- **5.1 (Mouse) :** trains de même taille contaminés à 0 %, 5 % et 10 % par **remplacement** de normaux ($x = \mu + 3\sigma \circledcirc \varepsilon$) ; test réel fixe ; IF/LOF hyperparams fixes ; 3 graines → moyenne ± écart-type de l'AP.
  - LOF : AP ≈ 0.97–0.99, très stable ;
  - IF : AP plus basse (≈ 0.75 à 0 %) puis ≈ 0.85–0.86 à 5–10 %, variance plus forte ;
  - la contamination n'effondre pas les performances avec ce générateur ; les conclusions **dépendent** du générateur synthétique.
- **5.2 (Credit Card, SHAP) :** l'explicateur porte sur la longueur moyenne de chemin h(x) de l'Isolation Forest, et non sur le score final. Après inversion, une contribution positive pousse vers l'alerte. Les fraudes détectées sont portées par V10, V14 et V3 ; les fausses alertes par V1, V20, V21, V27 et V28 ; les fraudes manquées ont un signal sur V14, V10 et V17, sans les variables V8 et V7 qui sont fortes chez les fraudes détectées.

Interprétation de l'explicabilité (SHAP)

L'analyse des valeurs SHAP offre un regard critique sur la logique décisionnelle interne de l'Isolation Forest. Bien que les variables initiales soient issues d'une ACP et donc totalement anonymisées (V1 à V28), l'outil d'explicabilité permet d'identifier l'existence de profils distincts d'anomalies. Les vraies fraudes correctement détectées sont systématiquement isolées grâce à une combinaison de variables spécifiques (notamment V10, V14, V3), indiquant une "signature" claire du comportement frauduleux dans cet espace réduit. À l'inverse, les fausses alertes sont dominées par un ensemble de variables totalement différent (V1, V20, V21, V27, V28). Cela suggère fortement que le modèle isole ces points non pas parce qu'ils ressemblent à des fraudes, mais parce qu'ils appartiennent à un sous-groupe minoritaire de comportements normaux extrêmes. Cette interprétation valide l'hypothèse soulevée précédemment : l'Isolation Forest manque de précision car il regroupe sous une même étiquette algorithmique des phénomènes générateurs fondamentalement distincts.

7. Contraintes métier atteintes ou non

Système	Contrainte	Résultat sur le Test	Statut
Régression logistique, SMOTE (Credit Card)	Précision ≥ 80 %	87.95 %	Atteinte
EasyEnsemble (Credit Card)	Précision ≥ 80 %	79.31 %	Non atteinte
Isolation Forest, LOF (Credit Card)	Précision ≥ 80 %	23.23 % et 54.70 %	Non atteintes
Régression logistique (AI4I)	Précision ≥ 90 %	100 % (rappel 2.9 %)	Atteinte en précision, mais rappel très faible
Isolation Forest (AI4I)	Précision ≥ 90 %	100 % (rappel 1.5 %)	Atteinte en précision, mais rappel très faible

8. Limites de généralisation

- **Taille des classes positives :** 95 fraudes au Test et 94 à la Validation ; 10 anomalies seulement sur Mouse ; 68 pannes au Test AI4I. Un écart d'une ou deux observations modifie sensiblement précision et rappel.
- **Un seul découpage :** les résultats Credit / AI4I sont obtenus avec `random_state=42`. Seule la Partie 5.1 mesure la variabilité sur plusieurs graines.
- **Données :** Credit Card est anonymisé (V1 à V28 issues d'une ACP), couvre 48 heures de 2013 et ne permet pas d'affirmer un comportement actuel. AI4I et Mouse sont synthétiques.
- **Découpage aléatoire :** la fuite temporelle est discutée mais non évitée ; un découpage temporel donnerait une estimation plus réaliste.
- **Seuil proche de 1 (Credit) :** le seuil retenu est sensible à SMOTE ; un autre rééchantillonnage ou une autre calibration donnerait un seuil différent.
- **Transfert AI4I :** respecter une précision ≥ 90 % peut rendre le système opérationnellement peu utile (presque aucune panne détectée).
- **SHAP :** six cas illustrent les mécanismes du modèle, sans permettre de conclure sur l'ensemble des alertes. Une contribution n'est pas une cause, et les variables anonymisées n'ont pas de sens métier restituable.

9. Reproductibilité

- Dépendances : `requirements.txt`.
- Notebooks exécutés : `partie2et3_fraudes.ipynb` (Parties 2, 3 et 5.2), `partie4.ipynb` (Partie 4), `mouse.ipynb` (Parties 1 et 5.1).
- Fonctions réutilisées : `utils_credit.py`, `utils_partie3.py`, `utils_partie5.py`, `utils_mouse.py`, `utils_ai4i.py`.